


1. 残差网络

残差网络 (ResNet) 是深度学习中里程碑式的模型架构。不妨考虑分类学习问题, 即给定输入数据及其标签 $\{y, h(y)\}_{y \in \Omega}$, 残差网络的前向传播过程如下:



在得到神经网络对输入数据 $y \in \Omega$ 的分类预测 $T(X_L)$ 后, 便可将其与真实标签 $h(y)$ 进行比较, 从而得到损失函数 (例如交叉熵)

$$\mathcal{L}(X_L) = \mathbb{E}_{y \in \Omega} [\|T(X_L) - h(y)\|]$$

不同于卷积层的简单堆叠, 残差模块中引入了恒同映射

$$X_{e+1} = X_e + F(X_e, W_e), \quad 0 \leq e \leq L-1$$

其中 W_e 代表模型参数, 从而有效解决了梯度爆炸的问题。

综上所述, 用残差网络做分类任务的优化问题可写为

$$\arg \min_{\{W_e\}_{e=0}^L} \left\{ \mathcal{L}(X_L) \mid X_0 = S(y); X_{e+1} = X_e + F(X_e, W_e), 0 \leq e \leq L-1 \right\}$$

其中模型参数的更新采用经典的反向传播算法, 即

$$W_e \leftarrow W_e - \eta \frac{\partial \mathcal{L}(X_L)}{\partial X_{e+1}} \frac{\partial X_{e+1}}{\partial W_e}, \quad 0 \leq e \leq L-1.$$

其中 $\eta > 0$ 代表学习率。

2. 神经微分方程

若将残差模块看作是常微分方程的前向 Euler 离散格式, 则其相应的优化问题可写为:

$$\operatorname{argmin}_{w(t)} \left\{ \varphi(x(t_1)) \mid x(0) = S_{\varphi}; \frac{dx(t)}{dt} = f(t, x(t), w(t)), 0 < t \leq 1 \right\}$$

在科学计算领域, 上述问题可写为更一般的形式

损失泛函

$$\text{minimize } J[w(t)] = \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} L(t, x(t), w(t)) dt$$

状态变量

控制变量

$$\text{subject to } x(t_0) = x_0 \in \mathbb{R}^{m \times 1}; \quad \frac{dx(t)}{dt} = f(t, x(t), w(t)), t_0 < t \leq t_1$$

为了求解上述带约束的最优化问题, 引入 Lagrange 乘子

伴随变量

$$p(t) = [p_1(t), p_2(t), \dots, p_m(t)]^T \in \mathbb{R}^{1 \times m}$$

将其改写为无约束的最优化问题, 即增广 Lagrange 泛函

$$J_a[x, w, p] = \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} [L(t, x, w) + p(f(t, x, w) - \dot{x})] dt$$

(为了符号简便, 省略记号“ t ”, 并将对 t 求导记为“ $\dot{\cdot}$ ”)

$$= \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} [L + p f] dt - \int_{t_0}^{t_1} p \dot{x} dt$$

分部积分: $\int_{t_0}^{t_1} p \dot{x} dt = \int_{t_0}^{t_1} p dx = p x \Big|_{t_0}^{t_1} - \int_{t_0}^{t_1} \dot{p} x dt$

$$= \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} [L + p f + \dot{p} x] dt - p(t_1) x(t_1) + p(t_0) x(t_0)$$

记微分方程中控制变量微小扰动 δw 造成状态变量的变化为 δx , 则对应增广 Lagrange 泛函的变化为

$$\delta J_a = \left[\left(\frac{\partial \varphi}{\partial x} - p \right) \delta x \right]_{t=t_1} + \int_{t_0}^{t_1} \left[\left(\frac{\partial L}{\partial x} + p \frac{\partial f}{\partial x} + \dot{p} \right) \delta x + \left(\frac{\partial L}{\partial w} + p \frac{\partial f}{\partial w} \right) \delta w \right] dt$$

其中 $x(t_0)$ 为固定的, 因此 $\delta x|_{t=t_0} = 0$. 若 Lagrange 乘子满足

$$\begin{cases} \mathcal{J}(t_1) = \frac{\partial \mathcal{J}(x(t_1), t_1)}{\partial x}, \\ \frac{d\mathcal{J}(t)}{dt} = - \frac{\partial L(t, x(t), w(t))}{\partial x} - \mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial x}, \quad t_0 \leq t < t_1, \end{cases}$$

则增广 Lagrange 泛函的变化为

$$\delta J_a = \int_{t_0}^{t_1} \left(\frac{\partial L}{\partial w} + \mathcal{J} \frac{\partial f}{\partial w} \right) \delta w \, dt$$

因此 $w^*(t)$ 使得增广 Lagrange 泛函取得最小的必要条件为

$$\left[\frac{\partial L(t, x(t), w(t))}{\partial w} + \mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial w} \right]_{w(t)=w^*(t)} = 0, \quad t_0 \leq t \leq t_1.$$

神经微分方程的最优控制问题

特别的, 考虑 $\mathcal{J}(x(t_1), t_1) = \mathcal{G}(x(t_1))$, $L(t, x(t), w(t)) = 0$. 则神经微分方程最优控制问题的解满足,

$$\begin{cases} x^*(0) = x_0; \quad \frac{dx^*(t)}{dt} = f(t, x^*(t), w^*(t)), \quad 0 \leq t \leq 1 & \text{[状态方程]} \\ \mathcal{J}^*(1) = \frac{d\mathcal{G}(x^*(1))}{dx}; \quad \frac{d\mathcal{J}^*(t)}{dt} = -\mathcal{J}^*(t) \frac{\partial f(t, x^*(t), w^*(t))}{\partial x}, \quad 0 \leq t < 1 & \text{[伴随方程]} \\ \mathcal{J}^*(t) \frac{\partial f(t, x^*(t), w^*(t))}{\partial w} = 0, \quad 0 \leq t \leq 1 & \text{[控制方程]} \end{cases}$$

若改写为迭代格式, 即为


$$\begin{cases} x(0) = x_0; \quad dx(t) = f(t, x(t), w(t)), \quad 0 \leq t \leq 1 & \text{[前向传播]} \\ \mathcal{J}(1) = \frac{d\mathcal{G}(x(1))}{dx}; \quad d\mathcal{J}(t) = -\mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial x}, \quad 0 \leq t < 1 \\ w(t) \leftarrow w(t) - \eta \mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial w}, \quad 0 \leq t \leq 1 \end{cases} \quad \text{[反向传播]}$$

这与离散情形下 ResNet 的前向-反向传播完全一致,

特别的, 当 $w(t)$ 与时间变量 t 无关时, 最后一式可改写为

$$W \leftarrow W - \eta \int_0^1 \beta(t) \frac{\partial f(t, x(t), w(t))}{\partial w} dt.$$

3. 常微分方程数值解



考虑神经微分方程的前向传播过程 (假设控制变量 $w(t)$ 与 t 无关)

$$x(0) = x_0; \quad dx(t) = f(t, x(t), w), \quad 0 < t \leq 1$$

从初值随时间演化到 $t=1$ 时刻的解可写为

$$x(1) = x_0 + \int_0^1 f(t, x(t), w) dt$$

当上述积分项无法解析求解时, 可采用数值积分近似计算。例如将计算区域进行等距划分 $0 = t_0 < t_1 < \dots < t_N = 1$, 其中节点 $x_n = x_0 + nh$, 步长 $h = \frac{1}{N}$, 则向前 Euler 格式可写为:

$$\hat{x}_0 = x_0; \quad \hat{x}_{n+1} = \hat{x}_n + h f(t_n, \hat{x}_n, w), \quad n = 0, 1, \dots, N-1.$$

可简记为

$$x(1) = \text{ODE_Solver} \left(\overset{\text{ODE求解器}}{f(t, x(t), w)}, \overset{\text{初值}}{x(0)}, \overset{\text{终止时刻}}{0, 1} \right)$$

$\hookrightarrow$ 状态方程右端项 $\hookrightarrow$ 初始时刻

在得到 $x(t)$ 后, 便可求解对偶方程 (逆向 ODE):

$$p(1) = \frac{d\varphi(x(1))}{dx}; \quad dp(t) = -p(t) \frac{\partial f(t, x(t), w)}{\partial x}, \quad 0 \leq t < 1$$

即调用

$$p(0) = \text{ODE_Solver} \left(\overset{\text{对偶方程右端项}}{-p(t) \frac{\partial f(t, x(t), w)}{\partial x}}, \overset{\text{初值}}{\frac{d\varphi}{dx}(x(1))}, \overset{\text{终止时刻}}{1, 0} \right)$$

$\hookrightarrow$ 初始时刻

注意到 $w(t)$ 与 t 无关, 因此控制变量的更新可调用

$$w \leftarrow w - \eta \Delta w$$

$\nwarrow$ 负梯度方向 $\nwarrow$ 下降步长

$$\Delta w = \int_0^1 p(t) \frac{\partial f(t, x(t), w)}{\partial w} dt = \text{ODE_Solver} \left(\overset{\text{控制方程右端项}}{p(t) \frac{\partial f(t, x(t), w)}{\partial w}}, \overset{\text{初值}}{0}, \overset{\text{终止时刻}}{0, 1} \right)$$

$\nwarrow$ 初值 $\nwarrow$ 终止时刻

4. 应用与扩展

自然而然的, 可以用神经微分方程来解决分类问题、生成模型等诸多应用问题, 有着广泛的应用场景。特别的, 由神经网络表达的右端项 $f(t, x(t), w(t))$ 拥有强大的拟合能力, 可根据学习任务演化非常复杂的动力学行为 (详情参见 Jupyter Notebook)。

当然, 神经微分方程方法也存在有局限性, 需要进一步改进以增强其表达能力, 例如 Augmented Neural ODEs (详情参见 Jupyter Notebook)。

此外，常微分方程的最优控制问题与 Hamilton-Jacobi-Bellman 方程有着密切的联系，感兴趣的同学可以进一步学习。