


1. 残差网络

残差网络 (ResNet) 是深度学习中里程碑式的模型架构。不妨考虑分类学习问题, 即给定输入数据及其标签 $\{y, h(y)\}_{y \in \Omega}$, 残差网络的前向传播过程如下:



在得到神经网络对输入数据 $y \in \Omega$ 的分类预测 $T(X_L)$ 后, 便可将其与真实标签 $h(y)$ 进行比较, 从而得到损失函数 (例如交叉熵)

$$\mathcal{L}(X_L) = \mathbb{E}_{y \in \Omega} [\|T(X_L) - h(y)\|]$$

不同于卷积层的简单堆叠, 残差模块中引入了恒同映射

$$X_{e+1} = X_e + F(X_e, W_e), \quad 0 \leq e \leq L-1$$

其中 W_e 代表模型参数, 从而有效解决了梯度爆炸的问题。

综上所述, 用残差网络做分类任务的优化问题可写为

$$\argmin_{\{W_e\}_{e=0}^L} \left\{ \mathcal{L}(X_L) \mid X_0 = S(y); X_{e+1} = X_e + F(X_e, W_e), 0 \leq e \leq L-1 \right\}$$

其中模型参数的更新采用经典的反向传播算法, 即

$$W_e \leftarrow W_e - \eta \frac{\partial \mathcal{L}(X_L)}{\partial X_{e+1}} \frac{\partial X_{e+1}}{\partial W_e}, \quad 0 \leq e \leq L-1.$$

其中 $\eta > 0$ 代表学习率。

2. 神经微分方程

若将残差模块看作是常微分方程的前向 Euler 离散格式, 则其相应的优化问题可写为:

$$\operatorname{argmin}_{w(t)} \left\{ \varphi(x(t_1)) \mid x(t_0) = S_{\text{eq}}; \frac{dx(t)}{dt} = f(t, x(t), w(t)), 0 < t \leq 1 \right\}$$

在科学计算领域, 上述问题可写为更一般的形式

损失泛函

$$\text{minimize } J[w(t)] = \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} L(t, x(t), w(t)) dt$$

状态变量

控制变量

$$\text{subject to } x(t_0) = x_0 \in \mathbb{R}^{m \times 1}; \quad \frac{dx(t)}{dt} = f(t, x(t), w(t)), \quad t_0 < t \leq t_1$$

为了求解上述带约束的最优化问题, 引入 Lagrange 乘子

伴随变量 $\leftarrow p(t) = [p_1(t), p_2(t), \dots, p_m(t)]^T \in \mathbb{R}^{1 \times m}$

将其改写为无约束的最优化问题, 即增广 Lagrange 泛函

$$J_a[x, w, p] = \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} [L(t, x, w) + p(f(t, x, w) - \dot{x})] dt$$

(为了符号简便, 省略记号“ t ”, 并将对 t 求导记为“ $\dot{\cdot}$ ”)

$$= \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} [L + p f] dt - \int_{t_0}^{t_1} p \dot{x} dt$$

分部积分: $\int_{t_0}^{t_1} p \dot{x} dt = \int_{t_0}^{t_1} p dx = p x \Big|_{t_0}^{t_1} - \int_{t_0}^{t_1} \dot{p} x dt$

$$= \varphi(x(t_1), t_1) + \int_{t_0}^{t_1} [L + p f + \dot{p} x] dt - p(t_1) x(t_1) + p(t_0) x(t_0)$$

记微分方程中控制变量微小扰动 δw 造成状态变量的变化为 δx , 则对应增广 Lagrange 泛函的变化为

$$\delta J_a = \left[\left(\frac{\partial \varphi}{\partial x} - p \right) \delta x \right]_{t=t_1} + \int_{t_0}^{t_1} \left[\left(\frac{\partial L}{\partial x} + p \frac{\partial f}{\partial x} + \dot{p} \right) \delta x + \left(\frac{\partial L}{\partial w} + p \frac{\partial f}{\partial w} \right) \delta w \right] dt$$

其中 $x(t_0)$ 为固定的, 因此 $\delta x|_{t=t_0} = 0$. 若 Lagrange 乘子满足

$$\begin{cases} \mathcal{J}(t_1) = \frac{\partial \mathcal{J}(x(t_1), t_1)}{\partial x}, \\ \frac{d\mathcal{J}(t)}{dt} = - \frac{\partial L(t, x(t), w(t))}{\partial x} - \mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial x}, \quad t_0 \leq t < t_1, \end{cases}$$

则增广 Lagrange 泛函的变化为

$$\delta J_a = \int_{t_0}^{t_1} \left(\frac{\partial L}{\partial w} + \mathcal{J} \frac{\partial f}{\partial w} \right) \delta w \, dt$$

因此 $w^*(t)$ 使得增广 Lagrange 泛函取得最小的必要条件为

$$\left[\frac{\partial L(t, x(t), w(t))}{\partial w} + \mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial w} \right]_{w(t)=w^*(t)} = 0, \quad t_0 \leq t \leq t_1.$$

神经微分方程的最优控制问题

特别的, 考虑 $\mathcal{J}(x(t_1), t_1) = \mathcal{G}(x(t_1))$, $L(t, x(t), w(t)) = 0$. 则神经微分方程最优控制问题的解满足,

$$\begin{cases} x^*(0) = x_0; \quad \frac{dx^*(t)}{dt} = f(t, x^*(t), w^*(t)), \quad 0 \leq t \leq 1 & \text{[状态方程]} \\ \mathcal{J}^*(1) = \frac{d\mathcal{G}(x^*(1))}{dx}; \quad \frac{d\mathcal{J}^*(t)}{dt} = -\mathcal{J}^*(t) \frac{\partial f(t, x^*(t), w^*(t))}{\partial x}, \quad 0 \leq t < 1 & \text{[伴随方程]} \\ \mathcal{J}^*(t) \frac{\partial f(t, x^*(t), w^*(t))}{\partial w} = 0, \quad 0 \leq t \leq 1 & \text{[控制方程]} \end{cases}$$

若改写为迭代格式, 即为


$$\begin{cases} x(0) = x_0; \quad dx(t) = f(t, x(t), w(t)), \quad 0 \leq t \leq 1 & \text{[前向传播]} \\ \mathcal{J}(1) = \frac{d\mathcal{G}(x(1))}{dx}; \quad d\mathcal{J}(t) = -\mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial x}, \quad 0 \leq t < 1 \\ w(t) \leftarrow w(t) - \eta \mathcal{J}(t) \frac{\partial f(t, x(t), w(t))}{\partial w}, \quad 0 \leq t \leq 1 \end{cases} \quad \text{[反向传播]}$$

这与离散情形下 ResNet 的前向-反向传播完全一致,

特别的, 当 $w(t) \equiv w$ 时即为原始版本的神经微分方程, 且此时

$$w \leftarrow w - \eta \int_0^1 \beta(t) \frac{\partial f(t, x(t), w(t))}{\partial w} dt.$$

3. 常微分方程数值解



考虑神经微分方程的前向传播过程 (假设控制变量 $w(t)$ 与 t 无关)

$$x(0) = x_0; \quad dx(t) = f(t, x(t), w), \quad 0 \leq t \leq 1$$

从初值随时间演化到 $t=1$ 时刻的解可写为

$$x(1) = x_0 + \int_0^1 f(t, x(t), w) dt$$

当上述积分项无法解析求解时, 可采用数值积分近似计算。例如

将计算区域进行等距划分 $0 = t_0 < t_1 < \dots < t_N = 1$, 其中节点 $x_n = x_0 + nh$,

步长 $h = \frac{1}{N}$, 则向前 Euler 格式可写为:

$$\hat{x}_0 = x_0; \quad \hat{x}_{n+1} = \hat{x}_n + h f(t_n, \hat{x}_n, w), \quad n = 0, 1, \dots, N-1.$$

可简记为

$$x(1) = \text{ODE_Solver} \left(\overset{\text{ODE求解器}}{f(t, x(t), w)}, \overset{\text{初值}}{x(0)}, \overset{\text{终止时刻}}{0, 1} \right)$$

$\hookrightarrow$ 状态方程右端项 $\hookrightarrow$ 初始时刻

在得到 $x(t)$ 后, 便可求解对偶方程 (逆向 ODE):

$$p(1) = \frac{d\varphi(x(1))}{dx}; \quad dp(t) = -p(t) \frac{\partial f(t, x(t), w)}{\partial x}, \quad 0 \leq t < 1$$

即调用

$$p(0) = \text{ODE_Solver} \left(\overset{\text{对偶方程右端项}}{-p(t) \frac{\partial f(t, x(t), w)}{\partial x}}, \overset{\text{初值}}{\frac{d\varphi}{dx}(x(1))}, \overset{\text{终止时刻}}{1, 0} \right)$$

$\hookrightarrow$ 初始时刻

注意到 $w(t)$ 与 t 无关, 因此控制变量的更新可调用

$$w \leftarrow w - \eta \Delta w$$

$\nwarrow$ 负梯度方向 $\nwarrow$ 下降步长

$$\Delta w = \int_0^1 p(t) \frac{\partial f(t, x(t), w)}{\partial w} dt = \text{ODE_Solver} \left(\overset{\text{控制方程右端项}}{p(t) \frac{\partial f(t, x(t), w)}{\partial w}}, \overset{\text{初值}}{0}, \overset{\text{终止时刻}}{0, 1} \right)$$

$\nwarrow$ 初值 $\nwarrow$ 终止时刻

4. 应用与扩展

自然而然的, 可以用神经微分方程来解决分类问题、生成模型等诸多应用问题, 有着广泛的应用场景。特别的, 由神经网络表达的右端项 $f(t, x(t), w(t))$ 拥有强大的拟合能力, 可根据学习任务演化非常复杂的动力学行为 (详情参见 Jupyter Notebook)。

当然, 神经微分方程方法也存在有局限性, 需要进一步改进以增强其表达能力, 例如 Augmented Neural ODEs (详情参见 Jupyter Notebook)。

此外,常微分方程的最优控制问题与 Hamilton-Jacobi-Bellman 方程有着密切的联系,感兴趣的同学可以进一步学习。

输运方程及其改进

考虑用神经微分方程求解数据的分类任务,在前向传播过程

$$x(0) = x_0; \quad \frac{dx(t)}{dt} = f(t, x(t), w), \quad 0 < t \leq 1,$$

结束后,特征 $x(1)$ 在通过输出层后转化为分类预测 $\text{softmax}(x(1))$ 并与真实标签 $h(x_0)$ 进行比较。

从输运方程 (transport equation) 的角度分析,即考虑终值问题

$$\begin{cases} \frac{\partial u(x,t)}{\partial t} + f(t, x, w) \cdot \nabla_x u(x,t) = 0, & x \in \mathbb{R}^d, t > 0 \\ u(x, 1) = \text{softmax}(x) & x \in \mathbb{R}^d \end{cases}$$

其中 $u(x,t) \in C^1(\mathbb{R}^d \times \mathbb{R}_+)$ 代表 t 时刻特征 x 所对应的分类预测,

$f(t, x, w): \mathbb{R}_+ \times \mathbb{R}^d \mapsto \mathbb{R}^d$ 。特别的,神经微分方程可以看作作为输

运方程的特征线,则有

$$\begin{aligned} \frac{d u(x(t), t)}{dt} &= \frac{\partial u}{\partial t}(x(t), t) + \frac{dx(t)}{dt} \cdot \nabla_x u(x(t), t) \\ &= \frac{\partial u}{\partial t}(x(t), t) + f(t, x(t), w) \cdot \nabla_x u(x(t), t) = 0 \end{aligned}$$

即 $u(x(t), t)$ 的函数值沿着特征线保持不变,因此

$$u(x(0), 0) = u(x(1), 1) = \text{softmax}(x(1))$$

故神经微分方程的训练任务可写为倒向输运方程的控制问题

$$\min_w \mathbb{E}_{y \in \Omega} [u(x_0, 0) - h(x_0)]$$

$$\text{s.t.} \begin{cases} \frac{\partial u}{\partial t}(x,t) + f(t, x, w) \cdot \nabla_x u(x,t) = 0, & x \in \mathbb{R}^d, t > 0 \\ u(x, 1) = \text{softmax}(x), & x \in \mathbb{R}^d \end{cases}$$

由于 $f(t, x, w)$ 通常较为复杂, 往往导致上述控制问题的目标函数高度非凸且优化困难。即便能够找到泛化能力较好的局部极小值, 其在对抗样本攻击下的稳定性也往往较差。

从偏微分方程的角度看, 即解对数据的扰动较为敏感, 需要提升其正则性来克服对抗攻击, 同时也有助于磨光目标函数来克服泛化性质较差的局部极小值 (sharp local minima)。

具体的讲, 在输运方程中添加一项耗散项, 即

$$\begin{cases} \frac{\partial U(x, t)}{\partial t} + f(t, x, w) \cdot \nabla_x U(x, t) + \frac{1}{2} \sigma^2 \Delta U(x, t) = 0, & x \in \mathbb{R}^d, t > 0 \\ U(x, 1) = \text{softmax}(x) & x \in \mathbb{R}^d \end{cases}$$

可证明在一定条件下 ($\sigma \leq 1$), 存在常数 $\alpha > 0$ 使得对于扰动 δ 有

$$|U(x + \delta, 0) - U(x, 0)| \leq C \left(\frac{\|\delta\|_2}{\sigma} \right)^2$$

特别的, 由 Feynman-Kac 公式可知, 上述问题可等价写为

$$U(x, 0) = \mathbb{E}[\text{softmax}(X(1)) \mid X(0) = x_0; dX(t) = f(t, X(t), w) dt + \sigma dW_t]$$

即把神经微分方程改写为神经随机微分方程并求多次模拟后的系综平均。在离散为 ResNet 结构后, 对应于使用 Dropout 或添加噪声后再求系综平均。

课后练习: ① 测试神经微分方程在对抗攻击下的稳定性, 并尝试用神经随机微分方程进行改进。

② 试用偏微分方程的理论来解释 Augmented NODE。