

1. 随机梯度下降算法

损失函数

有监督学习的任务可表达为：对于输入空间中的任意一样本 $x \in \Omega$ 及其对应的标签 $y \in \mathcal{A}$ ，寻找一个映射 $h: \Omega \mapsto \mathcal{A}$ 使得

$$h(x) = y$$

尽可能成立。换言之，所求映射需最小化期望意义下的损失函数

$$R(h) = \mathbb{E}_{x \in \Omega} [\mathbb{1}_{h(x) \neq y}], \text{ 其中 } \mathbb{1}_A = \begin{cases} 1, & \text{若事件 } A \text{ 成立} \\ 0, & \text{若事件 } A \text{ 不成立} \end{cases}$$

虽然上述定义是准确的，但其不连续性会对算法求解带来困扰，因此常用光滑的损失函数 $\ell: \mathcal{A} \times \mathcal{A} \mapsto \mathbb{R}$ 进行替代，即

$$\mathbb{1}_{h(x) \neq y} \approx \ell(h(x), y)$$

另一方面，实际问题往往只有离散的样本数据集 $\{(x_i, y_i)\}_{i=1}^n$ ，故而需最小化经验意义下的损失函数

$$R_n(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(h(x_i; \theta), y_i), \text{ 其中 } n \gg 1.$$

其中待求映射 $h(x; \theta)$ 通过可训练参数 θ 进行表达。

例：考虑给定数据集 $\{(x_i \in \mathbb{R}^d, y_i \in \mathbb{R})\}_{i=1}^n$ 的线性回归模型，即

$$h(x; \theta) = x^T \theta$$

其中 $\theta \in \mathbb{R}^d$ 且满足最小化问题

$$\min_{\theta \in \mathbb{R}^d} \frac{1}{n} \sum_{i=1}^n \frac{1}{2} [(x_i^T \theta - y_i)^2 + \lambda \|\theta\|^2]$$

↑ 正则项

其中 $\lambda > 0$ 为正则化参数。

优化算法

不妨考虑一般形式下的优化问题

$$\min_{\theta \in \mathbb{R}^d} f(\theta), \quad \text{其中 } f(\theta) = \frac{1}{n} \sum_{i=1}^n f_i(\theta)$$

其中 $n \geq 1$ 。若采用传统的梯度下降算法求解, 则迭代格式为

$$\theta_{k+1}^{\text{GD}} = \theta_k^{\text{GD}} - \eta_k \nabla f(\theta_k^{\text{GD}}) = \theta_k^{\text{GD}} - \frac{\eta_k}{n} \sum_{i=1}^n \nabla f_i(\theta_k^{\text{GD}})$$

若采用随机梯度下降算法求解, 则迭代格式为

$$\theta_{k+1}^{\text{SGD}} = \theta_k^{\text{SGD}} - \frac{\eta_k}{m} \sum_{\nu \in \mathcal{M}} \nabla f_{\nu}(\theta_k^{\text{SGD}})$$

其中 $\eta_k = 0$ 为步长, $\mathcal{M}$ 为从 $\{1, 2, \dots, n\}$ 中随机抽取 m 个元素所组成的集合。

备注: $m=n$ 时称为 full-batch gradient descent, 迭代一次称为 1 个 epoch

$m < n$ 时称为 mini-batch gradient descent, 迭代一次称为 $\frac{n}{m}$ 个 epoch

遍历全部数据为 1 个 epoch

2. 随机修正方程

为了更简捷的研究迭代格式的收敛性质及参数选取, 将采用微分方程的形式来刻画迭代解的收敛行为。举例来讲, 考虑

$$\min_{\theta \in \mathbb{R}} f(\theta) = \frac{1}{n} \sum_{i=1}^n f_i(\theta), \quad \text{其中 } \begin{cases} f_i(\theta) = (\theta - w_i)^2 \\ \nabla f_i(\theta) = 2(\theta - w_i) \end{cases}$$

其中 $n \geq 1$, $\{w_i\}_{i=1}^n$ 为服从正态分布 $N(\mu, \sigma^2)$ 的独立同分布随机变量。不难看出, 上述问题的真解为

$$\theta^* = \frac{1}{n} \sum_{i=1}^n w_i \approx \mu.$$

梯度下降算法, 假设步长 $\eta_k = \eta$ 为常数, 则迭代格式为

$$\theta_{k+1}^{GD} = \theta_k^{GD} - \frac{\eta}{n} \sum_{i=1}^n \nabla f_i(\theta_k^{GD}) = \theta_k^{GD} - 2\eta (\theta_k^{GD} - \theta^*)$$

可以看作下述常微分方程的向前 Euler 离散格式

$$d\theta(t)^{GD} = -\frac{\eta}{n} \sum_{i=1}^n \nabla f_i(\theta(t)^{GD}) = -2(\theta(t)^{GD} - \theta^*) dt.$$

特别的, 上述常微分方程可解析求解

$$\theta(t)^{GD} = \theta^* + (\theta_0^{GD} - \theta^*) e^{-2t} \quad \text{或} \quad e(t)^{GD} = e^{-2t} e_{(0)}^{GD}$$

其中 $e(t)^{GD} = \theta(t)^{GD} - \theta^*$ 表示与真解的误差, $\theta_0^{GD} = \theta_{(0)}^{GD}$ 为初值误差。

随机梯度下降算法, 假设步长 $\eta_k = \eta$ 为常数, 则迭代格式为

$$\begin{aligned} \theta_{k+1}^{SGD} &= \theta_k^{SGD} - \frac{\eta}{n} \sum_{\nu \in \mathcal{M}} \nabla f_{\nu}(\theta_k^{SGD}) \\ &= \theta_k^{SGD} - \frac{\eta}{n} \sum_{i=1}^n \nabla f_i(\theta_k^{SGD}) + \eta \left(\frac{1}{n} \sum_{i=1}^n \nabla f_i(\theta_k^{SGD}) - \frac{1}{n} \sum_{\nu \in \mathcal{M}} \nabla f_{\nu}(\theta_k^{SGD}) \right) \\ &= \theta_k^{SGD} - 2\eta (\theta_k^{SGD} - \theta^*) + \eta \left[2(\theta_k^{SGD} - \theta^*) - 2\left(\theta_k^{SGD} - \frac{1}{n} \sum_{\nu \in \mathcal{M}} w_{\nu}\right) \right] \\ &= \theta_k^{SGD} - 2\eta (\theta_k^{SGD} - \theta^*) + 2\eta \left[\frac{1}{n} \sum_{\nu \in \mathcal{M}} w_{\nu} - \theta^* \right] \end{aligned}$$

$$\text{其中 } \mathbb{E} \left[\frac{1}{n} \sum_{\nu \in \mathcal{M}} w_{\nu} - \theta^* \right] = 0$$

$$\begin{aligned} \mathbb{V} \left[\frac{1}{n} \sum_{\nu \in \mathcal{M}} w_{\nu} - \theta^* \right] &= \mathbb{E} \left[\left(\frac{1}{n} \sum_{\nu \in \mathcal{M}} (w_{\nu} - \theta^*) - 0 \right)^2 \right] \\ &= \frac{1}{n^2} \mathbb{E} \left[\left(\sum_{\nu \in \mathcal{M}} (w_{\nu} - \theta^*) \right) \left(\sum_{\nu' \in \mathcal{M}} (w_{\nu'} - \theta^*) \right) \right] \\ &= \frac{1}{n^2} \mathbb{E} \left[\sum_{\nu \in \mathcal{M}} (w_{\nu} - \theta^*)^2 + \sum_{\nu \neq \nu'} (w_{\nu} - \theta^*) (w_{\nu'} - \theta^*) \right] \\ &= \frac{\sigma^2}{n} \end{aligned}$$

$w_{\nu} \sim N(\mu, \sigma^2)$

因此迭代格式可写为

$$\begin{aligned}\theta_{k+1}^{\text{SGD}} &= \theta_k^{\text{SGD}} - 2\eta (\theta_k^{\text{SGD}} - \theta^*) + 2\eta N(0, \frac{\sigma^2}{m}) \\ &= \theta_k^{\text{SGD}} - 2\eta (\theta_k^{\text{SGD}} - \theta^*) + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} N(0, \eta)\end{aligned}$$

可以看作作为下述随机微分方程的 Euler-Maruyama 离散格式

$$d\theta_t^{\text{SGD}} = -2(\theta_t^{\text{SGD}} - \theta^*)dt + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} dW_t$$

定义: 如果一个实值随机过程 $W(\cdot)$ 满足

(1) $W(0) = 0$, a.s.

(2) $W(t) - W(s) \sim N(0, t-s)$ 对任意 $t \geq s > 0$, [正态分布]

(3) 对任意 $0 < t_1 < t_2 < \dots < t_n$, 随机变量 $W(t_1), W(t_2) - W(t_1), \dots, W(t_n) - W(t_{n-1})$ 相互独立, [独立增量]

则称 $W(\cdot)$ 为布朗运动 (Brownian motion, or Wiener process).

特别的, 对任意 $t > 0$, $E(W(t)) = 0$, $E(W^2(t)) = t$.

离散: 对随机微分方程

$$d\theta_t = -2(\theta_t - \theta^*)dt + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} dW_t$$

从 t_k 到 t_{k+1} 时刻积分可得 (其中 $t_{k+1} - t_k = \eta$)

$$\theta(t_{k+1}) - \theta(t_k) = \int_{t_k}^{t_{k+1}} -2(\theta(t) - \theta^*)dt + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} \int_{t_k}^{t_{k+1}} dW_t$$

↓ 左矩形数值积分公式

$$\approx -2(\theta(t_k) - \theta^*)\eta + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} W(t_{k+1}) - W(t_k)$$

$$\Rightarrow \theta_{k+1} = \theta_k - 2\eta(\theta_k - \theta^*) + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} N(0, \eta)$$

称之为 Euler-Maruyama 格式, 满足收敛条件

$$E[|\theta_k - \theta(t_k)|] \leq C\eta^{\frac{1}{2}},$$

strong order of convergence

$$|E[\theta_k] - E[\theta(t_k)]| \leq C\eta^2,$$

weak order of convergence

类似的, 可构造更高阶的数值格式, 如 Milstein 格式等。

为了得到随机修正方程

$$d\theta_{(t)}^{SGD} = -2(\theta_{(t)}^{SGD} - \theta^*)dt + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} dW_t$$

解的表达式, 需要用伊藤公式 (Itô's Formula)

$$\left(dX_{(t)} = Fdt + GdW_t \xrightarrow{Y_{(t)} = u(X_{(t)}, t)} dY_{(t)} = \frac{\partial u}{\partial t} dt + \frac{\partial u}{\partial x} dX_{(t)} + \frac{1}{2} \frac{\partial^2 u}{\partial x^2} G^2 dt \right. \\ \left. = \left(\frac{\partial u}{\partial t} + \frac{\partial u}{\partial x} F + \frac{1}{2} \frac{\partial^2 u}{\partial x^2} G^2 \right) dt + \frac{\partial u}{\partial x} G dW_t \right)$$

不妨令 $X_{(t)} = \theta_{(t)}^{SGD} - \theta^*$, 则随机修正方程可写为

$$dX_{(t)} = -2X_{(t)}dt + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} dW_t$$

考虑函数 $u(X_{(t)}, t) = X_{(t)} e^{2t}$, 则有

$$\frac{\partial u}{\partial t} = 2e^{2t} X_{(t)}; \quad \frac{\partial u}{\partial x} = e^{2t}; \quad \frac{\partial^2 u}{\partial x^2} = 0$$

$$\Rightarrow d(X_{(t)} e^{2t}) = [2e^{2t} X_{(t)} + e^{2t} (-2X_{(t)}) + 0]dt + e^{2t} \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} dW_t \\ = \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} e^{2t} dW_t$$

两边从 0 到 t 积分可得,

$$X_{(t)} = e^{-2t} X_{(0)} + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} \int_0^t e^{-2(t-s)} dW_s$$

$$\Rightarrow \theta_{(t)}^{SGD} = \theta^* + (\theta_0^{SGD} - \theta^*) e^{-2t} + \frac{2\sigma\sqrt{\eta}}{\sqrt{m}} \int_0^t e^{-2(t-s)} dW_s$$

特别的, 由随机积分的性质

Itô's Isometry: 对满足 $\mathbb{E}[\int_0^t G^2 dt] < \infty$ 的实值随机过程 $G(\cdot)$ 有

$$(1) \mathbb{E}[\int_0^t G dW_t] = 0,$$

$$(2) \mathbb{E}[(\int_0^t G dW_t)^2] = \mathbb{E}[\int_0^t G^2 dt]$$

可知误差 $e_{(t)}^{SGD} = \theta_{(t)}^{SGD} - \theta^*$ 满足

$$(1) \mathbb{E}[e_{(t)}^{SGD}] = e_{(0)}^{SGD} e^{-2t}$$

$$(2) \mathbb{V}[e_{(t)}^{SGD}] = \mathbb{E}[\frac{4\sigma^2\eta}{m} \int_0^t e^{-4(t-s)} ds] = \frac{\sigma^2\eta}{m} (1 - e^{-4t})$$

$$\Rightarrow e_{(t)}^{SGD} \sim N(e_{(0)}^{SGD} e^{-2t}, \frac{\eta\sigma^2}{m} (1 - e^{-4t}))$$

比较分析: 在同样初值 $\theta_0^{\text{GD}} = \theta_0^{\text{SGD}}$ 下, 从修正方程的角度对比误差

(*) 梯度下降: $e_{(t)}^{\text{GD}} = e^{-2t} e_{(0)}$

(*) 随机梯度下降: $e_{(t)}^{\text{SGD}} \sim N(e_{(0)} e^{-2t}, \frac{\eta \sigma^2}{m} (1 - e^{-4t}))$
 $= N(e_{(t)}^{\text{GD}}, \frac{\eta \sigma^2}{m} (1 - e^{-4t}))$

可以得到结论

(1) 在迭代初期 (即 $t \ll 1$), $e_{(t)}^{\text{SGD}}$ 的方差接近于零, 即 $\theta_{(t)}^{\text{SGD}}$ 与 $\theta_{(t)}^{\text{GD}}$ 没有太大差别, 但前者的计算代价远小于后者;

(2) 在迭代末期 (即 $t \gg 1$), $e_{(t)}^{\text{SGD}}$ 的方差接近于常数 $\frac{\eta \sigma^2}{m}$, 即 $\theta_{(t)}^{\text{SGD}}$ 围绕着真解 θ^* 来回振荡而不收敛,

为了使得 $\theta_{(t)}^{\text{SGD}}$ 收敛到 θ^* , 常见的做法包括 **减小迭代步长** $\eta \downarrow 0$ 或 **增大批量采样** $m \uparrow n$, 均有助于减小方差。此外, 该案例所对应的随机修正方程属于 **Ornstein-Uhlenbeck 过程**, 因此具备遍历性 (**Birkhoff's ergodic theorem**), 即时间平均等于系统平均, 且系统在长时间演化后与初值的选取无关

$$\lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T \theta_{(t)}^{\text{SGD}} dt = \int_{\Omega} \mu(\omega) d\omega, \text{ 其中 } \mu \text{ 为不变测度}$$

据此可在迭代解 θ_k^{SGD} 的基础上构造新的格式

$$\theta_{k+1}^{\text{ASGD}} = \frac{k}{k+1} \theta_k^{\text{ASGD}} + \frac{1}{k+1} \theta_{k+1}^{\text{SGD}}, \quad \theta_0^{\text{ASGD}} = \theta_0^{\text{SGD}}$$

来提升收敛性, 减少调整迭代步或采样数的代价。

思考: WNGrad 迭代格式所对应的随机修正方程是什么?

$$\begin{cases} x_{k+1} = x_k - \frac{1}{b_k} \nabla f(x_k) \\ b_{k+1} = b_k + \frac{1}{b_k} \|\nabla f(x_k)\|^2 \end{cases}$$

$$\text{由 } \frac{x_{k+1} - x_k}{b_{k+1} - b_k} = \frac{-\frac{1}{b_k} \nabla f(x_k)}{\frac{1}{b_k} \|\nabla f(x_k)\|^2} = -\frac{\nabla f(x_k)}{\|\nabla f(x_k)\|^2}$$

$$\text{可知修正方程为 } dx(t) = -\frac{\nabla f(x(t))}{\|\nabla f(x(t))\|^2} dt$$