

1. 反向随机微分方程

对于前向随机微分方程

$$\begin{cases} \bar{X}_0 \sim p_{\text{data}}(x) \\ d\bar{X}_t = f(\bar{X}_t, t) dt + g(t) dW_t, \quad t \in [0, T], \end{cases}$$

其中 $\bar{X}_t \in \mathbb{R}^d$ 表示状态变量, W_t 为标准的 d 维的 Wiener 过程, 漂移系数 $f: \mathbb{R}^d \times [0, T] \rightarrow \mathbb{R}$ 决定演变的趋势, 扩散系数 $g: [0, T] \rightarrow \mathbb{R}$ 决定噪声的强度, $p_{\text{data}}(x)$ 为样本数据的概率密度函数.

其相应概率密度函数 $p(x, t)$ 的演化遵循 Fokker-Planck 方程

$$\begin{cases} \frac{\partial}{\partial t} p(x, t) = -\nabla \cdot (f(x, t) p(x, t)) + \frac{1}{2} g^2(t) \Delta p(x, t), \quad t \in [0, T], \\ p(x, 0) = p_{\text{data}}(x) \end{cases}$$

通过定义反向过程的状态变量 $\bar{Y}_s = \bar{X}_{T-s}$, 其中 $s \in [0, T]$, Anderson 在 1982 年的论文 << Reverse-time diffusion equation models >> 通过正向与反向过程所对应概率密度函数之间的关系

$$\bar{p}(x, s) = p(x, T-s), \quad s \in [0, T]$$

给出了反向过程所满足的随机微分方程 (Reverse-Time SDEs):

$$\begin{cases} \bar{Y}_0 \sim p(x, T) = p_{\text{noise}}(x) \\ d\bar{Y}_s = [-f(\bar{Y}_s, T-s) + g^2(T-s) \nabla \log p(\bar{Y}_s, T-s)] ds + g(T-s) d\bar{W}_s, \quad s \in [0, T]. \end{cases}$$

若使用前向过程的记号, 即变量替换 $\bar{X}_t = \bar{Y}_{T-t}$, 则等价于

$$\begin{cases} \bar{X}_T \sim p(x, T) = p_{\text{noise}}(x) \\ d\bar{X}_t = [f(\bar{X}_t, t) - g^2(t) \nabla \log p(\bar{X}_t, t)] dt + g(t) d\bar{W}_t, \quad t \in [T, 0] \end{cases}$$

其中 $\nabla \log p(x, t)$ 称为分类函数 (score function).

例：考虑一维的正向随机微分方程：

$$\begin{cases} \bar{X}_0 = 0 \\ d\bar{X}_t = dW_t, \quad t \in [0, T] \end{cases}$$

① 根据 Fokker-Planck 方程可知其概率密度函数满足

$$\begin{cases} \frac{\partial}{\partial t} p(x, t) = \frac{1}{2} \frac{\partial^2}{\partial x^2} p(x, t), \quad t \in (0, T]. \\ p(x, 0) = \delta(x). \end{cases}$$

即初始热源集中于 $x=0$ 处的热传导方程，其解析解为

$$p(x, t) = \frac{1}{\sqrt{2\pi t}} e^{-\frac{x^2}{2t}}$$

② 因此，分数函数为

$$\nabla \log p(x, t) = \nabla \left[\log \frac{1}{\sqrt{2\pi t}} - \frac{x^2}{2t} \right] = -\frac{x}{t}$$

x > 0 时，分数为负
x = 0 时，分数为零
x < 0 时，分数为正

③ 相应的，反向随机微分方程为

$$\begin{cases} \bar{Y}_0 \sim p(x, T) = \frac{1}{\sqrt{2\pi T}} e^{-\frac{x^2}{2T}} \\ d\bar{Y}_s = -\frac{\bar{Y}_s}{T-s} ds + d\bar{W}_s, \quad s \in [0, T]. \end{cases}$$

体现运动方向

由伊藤公式 (Itô's Formula) 知：对 $dX_t = Fdt + GdW_t$ 做

变换 $Y_t = u(X_t, t) \implies dY_t = \frac{\partial u}{\partial t} dt + \frac{\partial u}{\partial x} dX_t + \frac{1}{2} \frac{\partial^2 u}{\partial x^2} G^2 dt$

令 $u(x, t) = \frac{x}{T-t}$ ，则 $\frac{\partial u}{\partial t} = \frac{x}{(T-t)^2}$ ， $\frac{\partial u}{\partial x} = \frac{1}{T-t}$ ， $\frac{\partial^2 u}{\partial x^2} = 0$

$$\text{伊藤公式} \implies d\frac{\bar{Y}_s}{T-s} = \frac{\bar{Y}_s}{(T-s)^2} dt + \frac{1}{T-s} d\bar{Y}_s = \frac{d\bar{W}_s}{T-s}$$

两边在区间

$$[0, t] \text{ 上积分} \implies \frac{\bar{Y}_t}{T-t} - \frac{\bar{Y}_0}{T} = \int_0^t \frac{1}{T-s} d\bar{W}_s$$

$$\implies \bar{Y}_t = \frac{T-t}{T} \bar{Y}_0 + (T-t) \int_0^t \frac{1}{T-s} d\bar{W}_s$$

可知当 $t \rightarrow T$ 时， $\bar{Y}_t \rightarrow 0$ ，即返回了初始位置

其中分数函数在将状态变量拉回原点，且在 T 时刻作用无穷大

例: 考虑一维的正向随机微分方程 (Ornstein-Uhlenbeck Process):

$$\begin{cases} \bar{X}_0 \sim p_0(x) \\ d\bar{X}_t = \theta(\mu - \bar{X}_t)dt + \sigma dW_t, \quad t \in [0, T] \end{cases}$$

其中 $\theta > 0$ 为回归速度, μ 为长期均值, σ 为波动率.

① 根据 Fokker-Planck 方程可知其概率密度函数满足

$$\begin{cases} \frac{\partial}{\partial t} p(x, t) = -\frac{\partial}{\partial x} [\theta(\mu - x)p(x, t)] + \frac{\sigma^2}{2} \frac{\partial^2}{\partial x^2} p(x, t), \quad t \in [0, T] \\ p(x, 0) = p_0(x) \end{cases}$$

其格林函数为

$$G(x, t | y, 0) = \frac{1}{\sqrt{2\pi}\Sigma^2(t)} e^{-\frac{(x - M(y, t))^2}{2\Sigma^2(t)}}, \quad \text{其中} \begin{cases} M(y, t) = \mu + (y - \mu)e^{-\theta t} \\ \Sigma^2(t) = \frac{\sigma^2}{2\theta}(1 - e^{-2\theta t}) \end{cases}$$

由此可知 Fokker-Planck 方程的解析解为

$$p(x, t) = \int_{-\infty}^{+\infty} G(x, t | y, 0) p_0(y) dy.$$

特别的, 当 $t \rightarrow +\infty$ 时, $M(y, t) \rightarrow \mu$, $\Sigma^2(t) \rightarrow \frac{\sigma^2}{2\theta} := \Sigma^2$, 即

$$p(x, \infty) = \frac{1}{\sqrt{2\pi}\Sigma^2} e^{-\frac{(x-\mu)^2}{2\Sigma^2}} \int_{-\infty}^{+\infty} p_0(y) dy \sim N(\mu, \frac{\sigma^2}{2\theta})$$

② 因此, 函数函数为

$$\nabla \log p(x, t) = -\frac{1}{\Sigma^2(t)} \frac{\int_{-\infty}^{+\infty} (x - M(y, t)) G(x, t | y, 0) p_0(y) dy}{p(x, t)}$$

根据 Bayes 公式, 给定 t 时刻状态为 x 的条件下, 初始时刻的状态为 y 的概率密度函数

$$p(\bar{X}_0 | \bar{X}_t) = \frac{\overset{\text{似然函数 } G(x_t, t | x_0, 0)}{p(\bar{X}_t | \bar{X}_0)} \overset{\text{先验分布}}{p_0(x)}}{\underset{\text{边缘似然 (归一化常数)}}{p(x, t)}} \leftarrow \text{后验分布}$$

$$\Rightarrow \nabla \log p(x, t) = -\frac{1}{\Sigma^2(t)} \left(x - \mu - e^{-\theta t} (\mathbb{E}[\bar{X}_0 | \bar{X}_t = x] - \mu) \right)$$

• 当 $t \rightarrow \infty$ 时, $M(y, t) \rightarrow \mu$ 与初值无关, $\Sigma^2(t) \rightarrow \frac{\sigma^2}{2\theta} = \Sigma^2$.

$\Rightarrow \nabla \log P(x, t) \rightarrow -\frac{2\theta}{\sigma^2} (x - \mu)$ 对应于“加噪”过程

• 当 $t \rightarrow 0$ 时, $M(y, t) \rightarrow y$, $\Sigma^2(t) \approx \frac{\sigma^2}{2\theta} [1 - (1 - 2\theta t)] = \sigma^2 t$

$\Rightarrow \nabla \log P(x, t) \rightarrow \nabla \log P_0(x)$ 对应于“去噪”过程.

③ 相应的, 反向随机微分方程为

$$\begin{cases} \bar{Y}_0 \sim P(x, \infty) = N(\mu, \frac{\sigma^2}{2\theta}) \\ d\bar{Y}_s = \left[\theta(\bar{Y}_s - \mu) - \frac{\sigma^2}{\Sigma^2(T-s)} (\bar{Y}_s - \mu + e^{-\theta(T-s)} \mathbb{E}[\bar{Y}_0 - \mu | \bar{Y}_{T-s} = x]) \right] dt \\ \quad + \sigma d\bar{W}_s, \quad s \in (0, +\infty) \end{cases}$$

2. 前后方程的系数函数确定

在实际应用中, 前向随机微分方程

$$\begin{cases} \bar{X}_0 \sim P_{\text{data}}(x), \\ d\bar{X}_t = f(\bar{X}_t, t) dt + g(t) dW_t, \quad t \in [0, T], \end{cases}$$

需要在有限时间 T 内, 将状态所对应的概率密度函数收敛到一个已知的分布, 如标准正态分布 $N(0, I)$ 或均匀分布。因此, 漂移和扩散系数的选取包含有:

① 方差保持型 (Variance Preserving)

$$d\bar{X}_t = -\frac{1}{2} \beta(t) \bar{X}_t dt + \sqrt{\beta(t)} dW_t$$

其中 $\beta(t)$ 表示扩散率。由 Itô 公式可知该时间依赖的 OU 过程有解析解

$$\bar{X}_t = \bar{X}_0 e^{-\frac{1}{2} \int_0^t \beta(s) ds} + \int_0^t e^{-\frac{1}{2} \int_s^t \beta(z) dz} \sqrt{\beta(s)} dW_s$$

且 (a) 均值 $E[\bar{X}_t] = E[\bar{X}_0] e^{-\frac{1}{2} \int_0^t \beta(s) ds}$

(b) 方差 $V[\bar{X}_t] = (1 - e^{-\int_0^t \beta(s) ds}) I$ [Itô Isometry 公式]

(c) 转移核

$$p(\bar{X}_t = x | \bar{X}_0 = x_0) = N(x_0 e^{-\frac{1}{2} \int_0^t \beta(s) ds}, (1 - e^{-\int_0^t \beta(s) ds}) I)$$

当扩散率函数满足 $\int_0^\infty \beta(s) ds = +\infty$ 时, 可知, $\lim_{t \rightarrow \infty} E[\bar{X}_t] = 0$ 和 $\lim_{t \rightarrow \infty} V[\bar{X}_t] = I$, 即 $p(x, \infty) = N(0, I)$ 。

在实际计算中, 可取有限时间 T 使得 $p(x, \infty) \approx N(0, I)$ 即可。

② 方差爆炸型 (Variance Exploding)

$$d\bar{X}_t = g(t) dW_t$$

当 $t \rightarrow \infty$ 时, 方差趋向于无穷, 分布趋于平坦。

.....

3. 反向方程的分数出数确定

问题: $\bar{x}_0 \sim p_{\text{data}}(x)$ 为真实数据, $\bar{x}_1 \sim p_{\text{noise}}(x) \approx N(0, I)$ 为噪音分布, 考虑方差保持型正向随机微分方程,

$$d\bar{x}_t = -\frac{1}{2}\beta(t)\bar{x}_t dt + \sqrt{\beta(t)}dW_t, \quad t \in (0, 1]$$

其中 $\beta(t) = \beta_{\min} + t(\beta_{\max} - \beta_{\min})$, 则有

$$\begin{aligned} p(\bar{x}_t = x | \bar{x}_0 = x_0) &= N(x_0 e^{-\frac{1}{2}\int_0^t \beta(s)ds}, (1 - e^{-\int_0^t \beta(s)ds})I) \\ &= N(x_0 e^{-\frac{1}{4}(\beta_{\min} + \beta_{\max})}, (1 - e^{-\frac{1}{2}(\beta_{\min} + \beta_{\max})})I) \end{aligned}$$

在 $\beta_{\max}$ 取较大值时, 有 $p(\bar{x}_1 = x | \bar{x}_0 = x_0) \approx N(0, I)$.

此时, 反向过程为,

$$\begin{cases} \bar{y}_0 \sim N(0, I) \\ d\bar{y}_s = [\frac{1}{2}\beta(1-s)\bar{y}_s + \beta(1-s)\nabla \log p(1-s, \bar{y}_s)]dt + \sqrt{\beta(1-s)}d\bar{W}_s, \quad s \in (0, 1] \end{cases}$$

分数匹配: 虽然正向过程的方程已知, 但通过求解其 Fokker-Planck 方程

(Score Matching)
$$\begin{cases} \frac{\partial}{\partial t} p = -\nabla \cdot (f p) + \frac{1}{2} \theta^2 \Delta p, & t \in (0, T], \\ p(x, 0) = p_{\text{data}}(x) \end{cases}$$

来计算分数出数并不可行, 主要因为状态变量维数较高, 即维数灾难问题。通过 Green 函数进行卷积也面临着同样的问题

$$p(x, t) = \int_{\mathbb{R}^d} G(x, t | y, 0) p_{\text{data}}(y) dy.$$

① 为此, 使用“不惧”维数灾难问题的神经网络来近似分数函数

$$\min_{\theta} J_{\text{ESM}}(\theta) := \mathbb{E}_{t \in \mathcal{U}[0, 1]} \left[\lambda(t) \mathbb{E}_{p(x, t)} \left[\|S_{\theta}(x_t, t) - \nabla \log p(x_t, t)\|^2 \right] \right]$$

其中 $\lambda(t): [0, 1] \mapsto \mathbb{R}^+$ 为权函数 (ESM = Explicit Score Matching)。

② 根据 Bayes 公式, 后验分布满足 似然函数 $G(x_t, t | x_0, 0)$

后验分布 $\nwarrow p(\bar{x}_0 | \bar{x}_t) = \frac{p(\bar{x}_t | \bar{x}_0) p_{\text{data}}(x) \rightarrow \text{先验分布}}{p(x, t) \rightarrow \text{边缘似然}}$

经过推导可得到与 ESM 等价的优化问题, 即 DSM (Demising

Score Matching)

$$\min_{\theta} J_{\text{DSM}}(\theta) := \mathbb{E}_t \left[\lambda(t) \mathbb{E}_{\substack{\mathbf{x}_0 \\ q_{[0,1]}}} \mathbb{E}_{\substack{\mathbf{x}_t \\ p_{\text{data}}(\mathbf{x})} } \mathbb{E}_{\substack{\mathbf{x}_t \\ p(\mathbf{x}|\mathbf{x}_0)}} [\|S_{\theta}(\mathbf{x}_t, t) - \nabla \log p(\mathbf{x}_t|\mathbf{x}_0)\|^2] \right]$$

特别的, 对于之前的方差保持型正向随机微分方程, 有

$$\begin{aligned} p(\bar{\mathbf{x}}_t | \bar{\mathbf{x}}_0) &= N(\bar{\mathbf{x}}_0 e^{-\frac{1}{2} \int_0^t \beta(s) ds}, (1 - e^{-\int_0^t \beta(s) ds}) \mathbf{I}) \\ &= N(\bar{\mathbf{x}}_0 e^{-\frac{1}{4}(\beta_{\min} + \beta_{\max})}, (1 - e^{-\frac{1}{2}(\beta_{\min} + \beta_{\max})}) \mathbf{I}) \\ &:= N(\mathbf{M}(\bar{\mathbf{x}}_0, t), \Sigma^2(t)) \end{aligned}$$

$$\Rightarrow \nabla \log p(\mathbf{x}_t | \bar{\mathbf{x}}_0) = \frac{1}{\Sigma^2(t)} [\mathbf{M}(\bar{\mathbf{x}}_0, t) - \mathbf{x}_t]$$

$$\Rightarrow \min_{\theta} J_{\text{DSM}}(\theta) := \mathbb{E}_t \left[\mathbb{E}_{\substack{\mathbf{x}_0 \\ q_{[0,1]}}} \mathbb{E}_{\substack{\mathbf{x}_t \\ p_{\text{data}}(\mathbf{x})} } \mathbb{E}_{\substack{\mathbf{x}_t \\ p(\mathbf{x}|\mathbf{x}_0)}} [\|S_{\theta}(\mathbf{x}_t, t) + \frac{\mathbf{x}_t - \mathbf{M}(\bar{\mathbf{x}}_0, t)}{\Sigma^2(t)}\|^2] \right]$$